

СРАВНЕНИЕ МЕТОДОВ КЛАССИФИКАЦИИ ВЕБ-КОНТЕНТА ПО URL И ЗАГОЛОВКАМ СТРАНИЦ

И. А. Дулина^{1,*}, П. А. Мартынюк¹

¹ МГТУ им. Н.Э. Баумана

* *email: irisdulina@yandex.ru*

В работе сравниваются методы классификации веб-ресурсов на зашумлённом несбалансированном датасете. Рассмотрены TF-IDF с логистической регрессией, FastText и мультязычная модель семейства BERT. FastText показывает наилучший F1-score (0.988) при минимальных вычислительных затратах.

Ключевые слова: классификация текста, TF-IDF, FastText, BERT, фильтрация веб-контента, зашумлённые данные.

Введение. Фильтрация нежелательного веб-контента востребована в системах родительского контроля и корпоративных сетях. В высоконагруженных системах анализ полного текста нецелесообразен, поэтому задача сводится к классификации по URL и заголовку. Цель работы – сравнение методов с точки зрения качества и вычислительной эффективности.

Данные и методология. Датасет [1] (135 309 записей) имеет дисбаланс 7:1 и шум разметки. Предобработка включает извлечение значимых частей домена и токенизацию заголовков с фильтрацией стоп-слов. Сравниваются подходы к векторизации и классификации: TF-IDF + LogReg; FastText [2] с символьными n-граммами; компактный трансформер Multilingual-MiniLM [3]. Среда Google Colab: GPU NVIDIA T4, CPU Intel Xeon (2.20 ГГц). Инференс TF-IDF и FastText – на CPU, BERT – на GPU, что ограничивает его применение.

Результаты. Результаты представлены в таблице 1. FastText превосходит BERT по F1 и скорости. При этом BERT чаще допускает ложноположительные ошибки, что предпочтительно для задач фильтрации (рис. 1).

Анализ ошибок показал: 190 общих ошибок, вызванных шумом разметки; TF-IDF имеет 761 уникальную ошибку из-за слабого учета морфем; FastText и BERT взаимодополняют друг друга (105 и 100 уникальных верных предсказаний): их расхождения часто связаны с дефектами разметки датасета, а не ошибками моделей. UMAP-визуализация подтверждает хорошее разделение классов (рис. 1).

Таблица 1: Сравнение моделей (инференс на 5000 примеров)

Модель	F1	Время, с	RAM, МБ
TF-IDF + LR	0.972	~0.002	~29
FastText	0.9877	~0.13	~93
MiniLM (BERT)	0.9853	~309	~1460



Рис. 1: Матрицы ошибок FastText и MiniLM (слева, центр) и UMAP-визуализация эмбедингов MiniLM (справа): красный кластер – сайты для взрослых, синий – обычные

Заключение. Модель FastText обеспечивает лучшее соотношение качества и скорости. Модель BERT демонстрирует более предпочтительное распределение ошибок и устойчивость к сложным случаям. Перспективное направление – ансамблевый подход: FastText для потоковой фильтрации, BERT для валидации сложных случаев.

Список литературы

- [1] Daracer Porn Detection. Kaggle [Электронный ресурс]. — URL: <https://www.kaggle.com/datasets/mickleburg/ml-2026-spring-porn-detection> (дата обращения: 17.04.2026).
- [2] Joulin A., Grave E., Bojanowski P., Mikolov T. Bag of Tricks for Efficient Text Classification // Proc. EACL. — 2017. — P. 427–431.
- [3] Wang W., Wei F., Dong L., Bao H., Yang N., Zhou M. MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers // Proc. NeurIPS. — 2020.